

RAPPORT D'INSPECTION DU JEU DE DONNÉES

HEART DISEASE CLEVELAND

Étudiant : Joseph MUSENGA

Promotion : Master 1 A.I

Cours : Data Preprocessing

Ce rapport présente les principaux résultats obtenus lors de l'inspection du jeu de données réalisée dans le notebook Python.

1. Introduction

Dans le cadre du cours de Data Preprocessing, j'ai travaillé sur le jeu de données Heart Disease Cleveland. Avant de passer aux étapes de nettoyage et de transformation, il était nécessaire de commencer par une inspection des données afin de comprendre leur structure et d'avoir une première idée de leur qualité.

L'objectif de cette première étape est donc d'examiner les dimensions du jeu de données, les types de variables, la présence éventuelle de valeurs manquantes ou de doublons, les modalités des variables et quelques statistiques descriptives. Le travail a été réalisé avec Python dans Jupyter Notebook, principalement avec la bibliothèque Pandas.

2. Démarche suivie

Le jeu de données a d'abord été chargé depuis mon repository GitHub. Après un premier aperçu des observations, j'ai vérifié ses dimensions et sa structure générale avec les fonctions de Pandas. J'ai ensuite recherché les valeurs manquantes et les observations dupliquées.

Comme toutes les colonnes sont enregistrées sous forme numérique, j'ai aussi examiné le nombre de valeurs distinctes et les modalités de chaque variable. Cette vérification était importante parce qu'une variable de type int64 dans Pandas n'est pas nécessairement une variable quantitative. Enfin, j'ai calculé les statistiques descriptives des principales variables quantitatives ainsi que les effectifs et pourcentages des variables catégorielles.

3. Résultats de l'inspection

3.1 Structure générale

Le jeu de données contient 303 observations et 14 variables. L'inspection avec `info()` montre que 13 variables sont de type int64 et que la variable `oldpeak` est de type float64. Toutes les colonnes sont donc encodées numériquement, mais l'examen des modalités montre que plusieurs d'entre elles sont en réalité des variables catégorielles codées par des nombres.

3.2 Valeurs manquantes et doublons

La vérification avec `isna()` n'a révélé aucune valeur manquante dans les 14 variables. Toutes les colonnes disposent donc de 303 valeurs renseignées. La recherche des doublons a également donné un résultat égal à zéro. À ce stade, aucune observation entièrement dupliquée n'a été détectée.

3.3 Nature des variables

L'examen des valeurs distinctes a permis de mieux différencier les variables. Les principales variables quantitatives retenues sont `age`, `trestbps`, `chol`, `thalach` et `oldpeak`. Les variables `sex`, `cp`, `fbs`, `restecg`, `exang`, `slope`, `thal` et `target` sont traitées comme des variables catégorielles encodées numériquement. La variable `ca`, qui

prend les valeurs de 0 à 3, correspond à un nombre discret et sera considérée selon les besoins des analyses suivantes.

3.4 Statistiques descriptives des variables quantitatives

Variable	Moyenne	Médiane	Minimum	Maximum
age	54,44	56	29	77
trestbps	131,69	130	94	200
chol	246,69	241	126	564
thalach	149,61	153	71	202
oldpeak	1,04	0,8	0	6,2

L'âge moyen est d'environ 54,44 ans, avec des valeurs comprises entre 29 et 77 ans. La pression artérielle au repos (trestbps) a une moyenne de 131,69 et le cholestérol (chol) une moyenne de 246,69. La fréquence cardiaque maximale (thalach) est en moyenne de 149,61, tandis que oldpeak présente une moyenne de 1,04.

Certains maxima sont assez éloignés des valeurs centrales, notamment 200 pour trestbps, 564 pour chol et 6,2 pour oldpeak. À ce niveau du travail, je les considère seulement comme des valeurs potentiellement atypiques. Une analyse spécifique des valeurs aberrantes sera nécessaire avant de décider si une correction ou une suppression est justifiée.

3.5 Répartition des variables catégorielles

L'analyse des effectifs et des pourcentages montre que certaines variables sont assez déséquilibrées. Pour sex, la modalité 1 représente 67,99 % des observations. Pour cp, la modalité 3 est la plus fréquente avec 47,52 %. La différence est particulièrement marquée pour fbs, où la modalité 0 représente 85,15 % des observations.

Pour restecg, les modalités 0 et 2 sont presque également représentées, avec respectivement 49,83 % et 48,84 %, alors que la modalité 1 ne représente que 1,32 %. Pour slope, les modalités 0 et 1 sont également proches, avec 46,86 % et 46,20 %. Enfin, la variable cible target est relativement équilibrée : 164 observations (54,13 %) pour la modalité 0 et 139 observations (45,87 %) pour la modalité 1.

4. Conclusion

Cette inspection m'a permis d'avoir une première compréhension du jeu de données avant de commencer le prétraitement proprement dit. Le dataset contient 303 observations et 14 variables. Je n'ai détecté ni valeur manquante ni observation entièrement dupliquée.

L'inspection a aussi montré qu'il ne faut pas se limiter aux types affichés par Pandas pour déterminer la nature statistique des variables, puisque plusieurs colonnes numériques correspondent en réalité à des catégories codées. Les statistiques descriptives ont par ailleurs fait ressortir quelques valeurs potentiellement atypiques,

notamment pour trestbps, chol et oldpeak, sans permettre à ce stade de conclure qu'elles sont aberrantes.

Cette étape servira donc de base pour la suite du travail. Les prochaines analyses permettront d'approfondir l'étude des distributions, des valeurs aberrantes et, selon les orientations du cours, de réaliser progressivement les opérations de nettoyage et de transformation nécessaires.